Reconocimiento de dígitos manuscritos

Caso práctico TecnoForms · Cifra

Siete modelos comparados: CNN, MLP, SVM, KNN, regresión logística, regresión lineal y K-Means.

Generado el 01/11/2026 con Google Colab. Mejor modelo: CNN (red convolucional) (98,69 % en el test).

1. Objetivo

TecnoForms necesita leer automáticamente los números escritos a mano en sus formularios (códigos, teléfonos, montos). Se construyó un sistema que toma la foto, separa cada dígito y lo clasifica, y se compararon siete algoritmos para elegir el mejor.

2. Datos

Datos de internet: MNIST, 60 000 dígitos para entrenar y 10 000 para el test final, escritos por personas reales; clases equilibradas (entre 5 421 y 6 742 imágenes por dígito).

Datos ficticios: formularios de inscripción, pago y solicitud, y números en hoja lisa o cuadriculada, armados con dígitos de MNIST y degradados (sombras, ruido, desenfoque, hojas torcidas y de colores). Se usan para probar el preprocesado y el sistema completo.

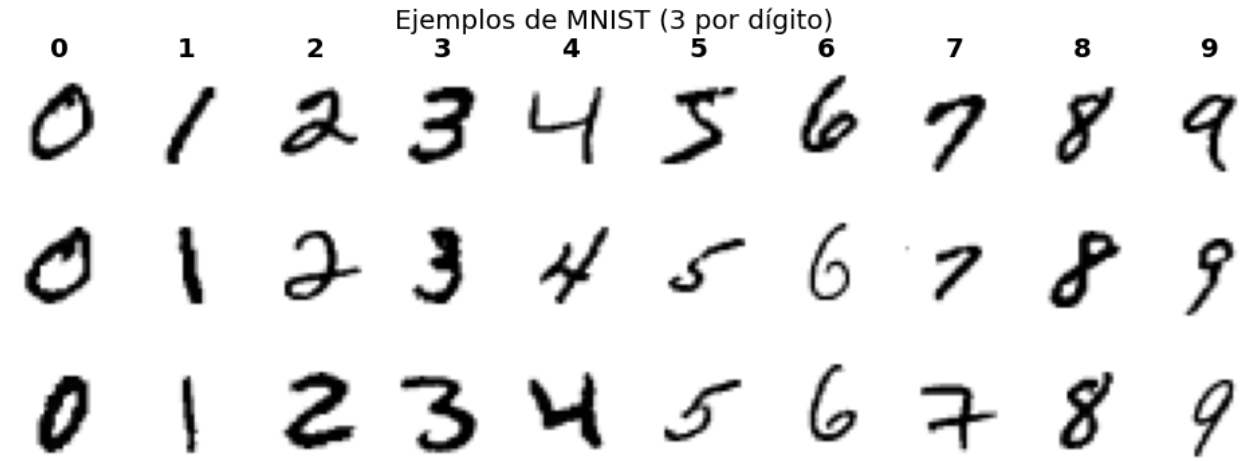


Figura 1. Ejemplos de MNIST (datos de internet).

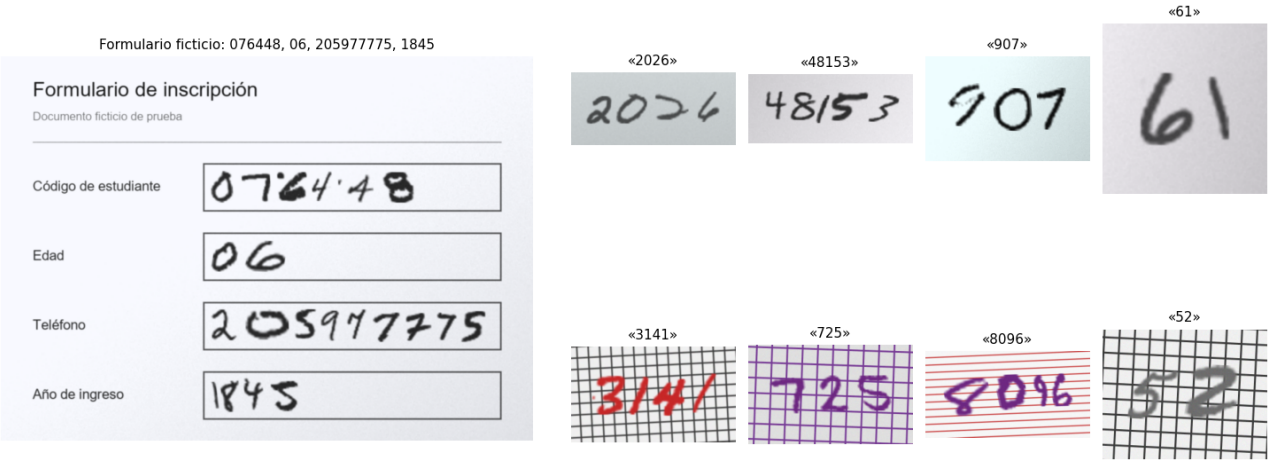


Figura 2. Formulario y números ficticios.

3. Preparación de las imágenes

Pasos: limitar el tamaño, escala de grises (eligiendo el canal de color que borra la cuadrícula), normalizar la iluminación dividiendo por el fondo, binarizar con Otsu, quitar líneas de cuadrícula o renglones, segmentar con componentes conectados (uniendo trazos de un mismo dígito y partiendo dígitos pegados), recortar cada dígito a 20 px centrado por centro de masa en 28 x 28 y normalizar a 0-1.

Razonamiento: los modelos aprenden con MNIST, así que cada recorte debe verse como un dígito de MNIST. Con el número de cifras conocido, la segmentación separó bien el 100,0 % de las imágenes ficticias de prueba.

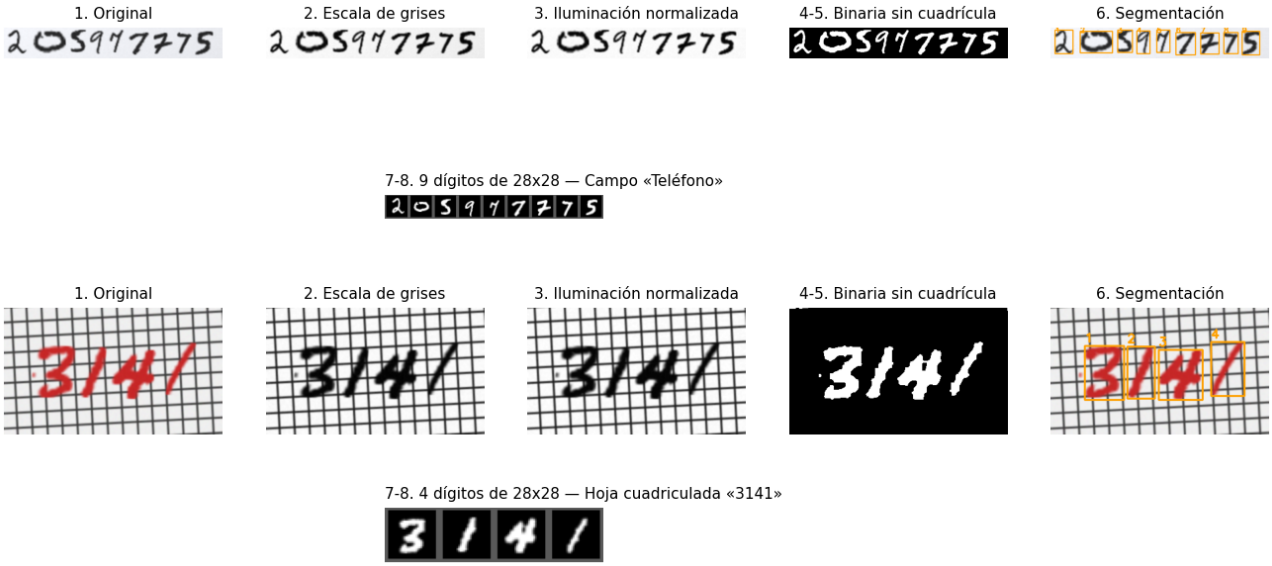


Figura 3. Preprocesado paso a paso en un campo de formulario y en una hoja cuadriculada.

Tipo	Imágenes	% sin ayuda	% sabiendo cuántos
Campo de formulario	40	100,00	100,00
Hoja cuadriculada	40	77,50	100,00
Hoja lisa	40	100,00	100,00

4. Algoritmos elegidos

Modelo principal: red neuronal convolucional (CNN), porque sus filtros detectan trazos y curvas en cualquier posición. Se compara con una red densa (MLP), SVM con núcleo RBF, KNN, regresión logística, regresión lineal y K-Means (no supervisado). SVM, KNN y K-Means trabajan sobre 50 componentes PCA para ir más rápido.

5. Arquitectura de la CNN

Dos bloques convolucionales (3x3, 16 y 32 filtros, ReLU y MaxPool 2x2), dropout 0,25, una capa densa de 64 neuronas ReLU y la salida de 10 neuronas con softmax; 105 866 parámetros. Optimizador Adam con tasa 0,003, entropía cruzada, lotes de 128 y 3 épocas.

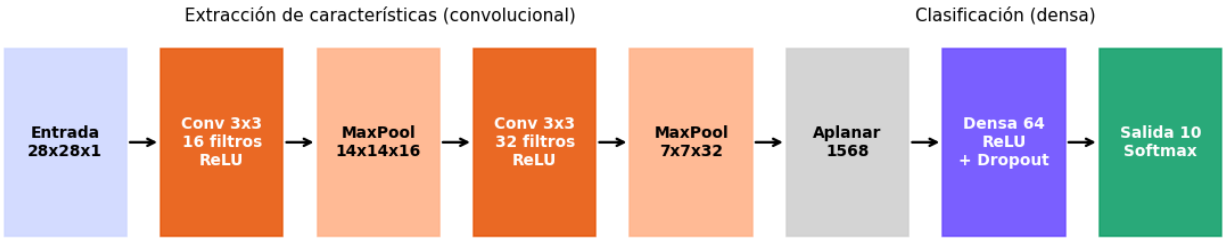


Figura 4. Arquitectura de la CNN.

Capa	Forma de salida	Nodos / filtros	Activación	Parámetros
Entrada	28 x 28 x 1	-	-	0
Conv2D 3x3 (relleno 1)	28 x 28 x 16	16 filtros	ReLU	160
MaxPool 2x2	14 x 14 x 16	-	-	0
Conv2D 3x3 (relleno 1)	14 x 14 x 32	32 filtros	ReLU	4640
MaxPool 2x2	7 x 7 x 32	-	-	0
Aplanar	1568	-	-	0
Dropout	1568	p = 0,25	-	0
Densa	64	64 neuronas	ReLU	100416
Dropout	64	p = 0,25	-	0
Densa (salida)	10	10 neuronas (dígitos 0-9)	Softmax	650

Capa	Forma de salida	Nodos / filtros	Activación	Parámetros
Entrada	784	28x28 aplanado	-	0
Densa	128	128 neuronas	ReLU	100480
Dropout	128	p = 0,2	-	0
Densa	64	64 neuronas	ReLU	8256
Densa (salida)	10	10 neuronas (dígitos 0-9)	Softmax	650

6. Entrenamiento, validación cruzada e hiperparámetros

Cada modelo probó una malla de hiperparámetros con validación cruzada estratificada de 5 pliegues sobre 5000 dígitos, y se quedó con la combinación de mejor exactitud media. Luego se entrenó con 30 000 dígitos (SVM 10 000 y KNN 20 000).

Elegidos: CNN filtros=16, tasa_aprendizaje=0,003; MLP neuronas=128, tasa_aprendizaje=0,003; SVM C=10, gamma=0,05; KNN k=7; Reg. logística C=0,1; Reg. lineal alpha=100,0; K-Means clusteres=60.

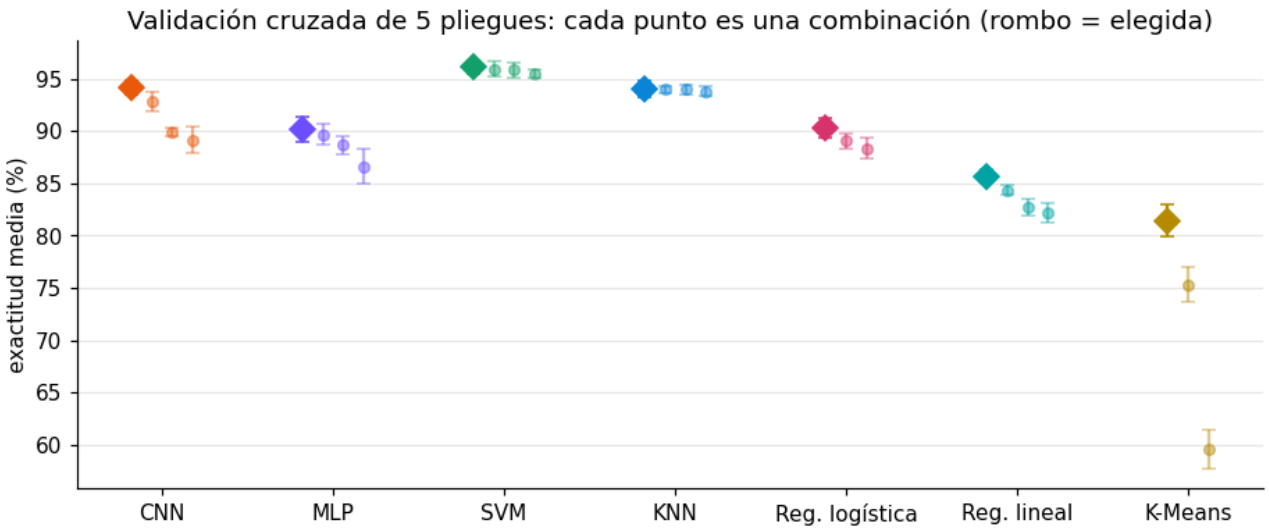


Figura 5. Validación cruzada de 5 pliegues.

Modelo	Hiperparámetros	Exactitud media	Desviación	Elegido
CNN	filtros=16, tasa_aprendizaje=0,003	0,94	0,01	✔
CNN	filtros=8, tasa_aprendizaje=0,003	0,93	0,01	
CNN	filtros=16, tasa_aprendizaje=0,001	0,90	0,00	

Modelo	Hiperparámetros	Exactitud media	Desviación	Elegido
CNN	filtros=8, tasa_aprendizaje=0,001	0,89	0,01	
MLP	neuronas=128, tasa_aprendizaje=0,003	0,90	0,01	✔
MLP	neuronas=64, tasa_aprendizaje=0,003	0,90	0,01	
MLP	neuronas=128, tasa_aprendizaje=0,001	0,89	0,01	
MLP	neuronas=64, tasa_aprendizaje=0,001	0,87	0,02	
SVM	C=10, gamma=0,05	0,96	0,01	✔
SVM	C=1, gamma=0,05	0,96	0,01	
SVM	C=10, gamma=scale	0,96	0,01	
SVM	C=1, gamma=scale	0,95	0,00	
KNN	k=7	0,94	0,01	✔
KNN	k=5	0,94	0,00	
KNN	k=3	0,94	0,00	
KNN	k=1	0,94	0,00	
Reg. logística	C=0,1	0,90	0,01	✔
Reg. logística	C=1,0	0,89	0,01	
Reg. logística	C=10,0	0,88	0,01	
Reg. lineal	alpha=100,0	0,86	0,01	✔
Reg. lineal	alpha=10,0	0,84	0,00	
Reg. lineal	alpha=1,0	0,83	0,01	
Reg. lineal	alpha=0,1	0,82	0,01	
K-Means	clusteres=60	0,81	0,02	✔
K-Means	clusteres=30	0,75	0,02	
K-Means	clusteres=10	0,60	0,02	

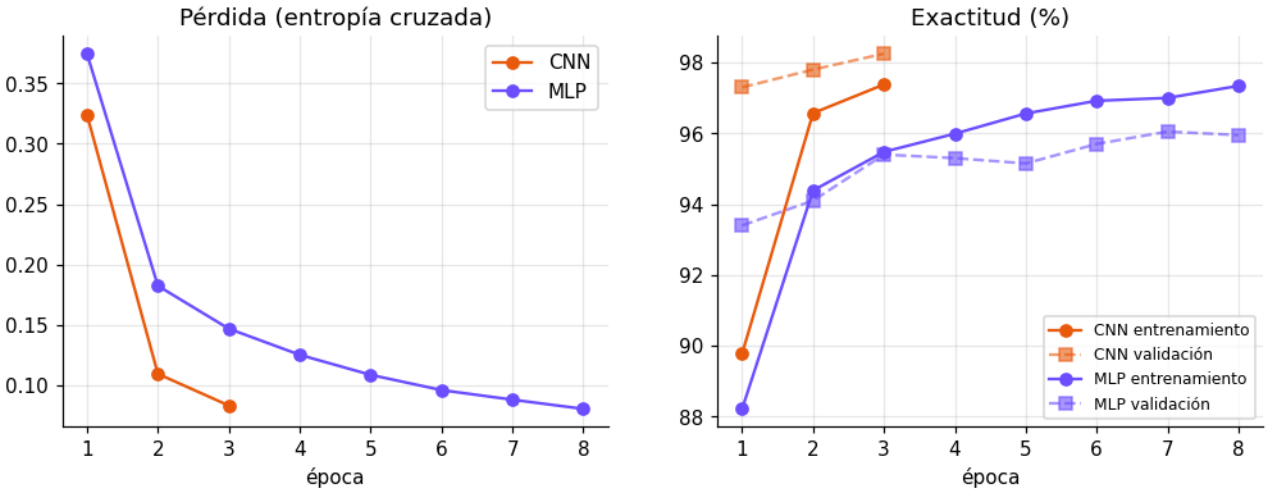


Figura 6. Curvas de entrenamiento de la CNN y la MLP.

7. Resultados en el test

El mejor modelo es la CNN (red convolucional) con 98,69 % de exactitud y F1 macro de 98,68 %: de 10 000 dígitos que nunca vio se equivocó en 131. Le sigue SVM (RBF) con 97,39 % (261 errores).

La CNN supera a la MLP (98,69 % frente a 96,85 % y con menos parámetros): las capas convolucionales reconocen trazos y curvas aunque el dígito esté corrido, mientras que la MLP ve cada píxel por separado.

SVM (97,39 %) y KNN (96,78 %), las alternativas pedidas, quedan cerca de las redes gracias a las 50 componentes PCA. Para leer un dígito tardan 0,742 ms (SVM) y 0,139 ms (KNN), frente a 0,375 ms de la CNN; la SVM compara cada dígito con sus vectores de soporte y KNN con todos los ejemplos que guardó, así que se vuelven más lentos cuantos más datos tienen.

Los modelos lineales tienen un techo: regresión logística 92,33 % y regresión lineal 86,25 %. Un único peso por píxel no puede representar las distintas formas de escribir un mismo dígito.

K-Means (85,04 %) no usa las etiquetas para aprender: agrupa dígitos parecidos y solo después cada grupo toma un nombre. Que llegue a ese valor muestra que los dígitos forman grupos naturales, pero confunde los que se escriben parecido.

La confusión más frecuente de la CNN es 4 → 9 (10 veces) y su dígito más difícil es el 9 (F1 97,86 %): son pares que también confunden las personas cuando la letra es descuidada.

En la validación cruzada la CNN tuvo una desviación de ±0,65 puntos entre pliegues: el resultado es estable y no depende de qué datos tocaron en cada parte.

Decisión: para TecnoForms se recomienda la CNN como modelo principal (la más exacta) y SVM como respaldo para comparar.

Modelo	Exactitud (%)	Precisión macro (%)	Recall macro (%)	F1 macro (%)	Errores (de 10 000)	ms por dígito
CNN (red convolucional)	98,69	98,68	98,68	98,68	131	0,38
SVM (RBF)	97,39	97,38	97,38	97,38	261	0,74
MLP (red densa)	96,85	96,89	96,80	96,83	315	0,01
KNN	96,78	96,81	96,76	96,77	322	0,14
Regresión logística	92,33	92,23	92,22	92,22	767	0,01
Regresión lineal	86,25	86,46	86,01	86,01	1375	0,01
K-Means	85,04	85,80	84,77	84,66	1496	0,00

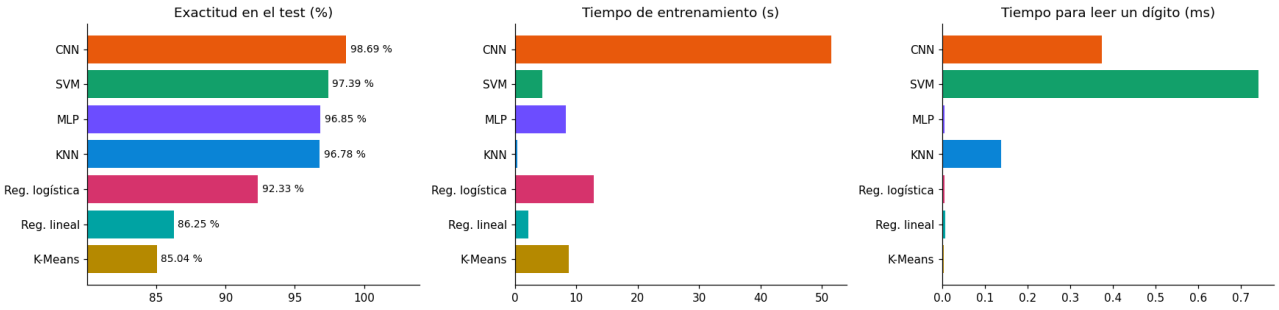


Figura 7. Comparación de exactitud y velocidad.

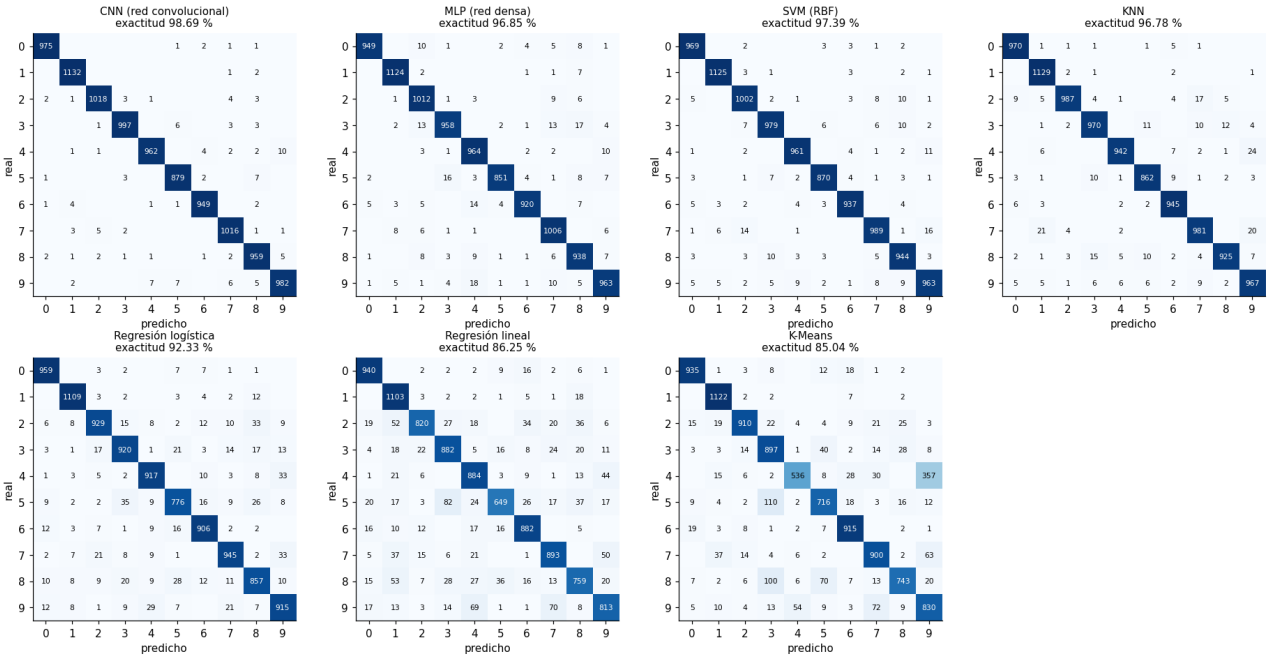


Figura 8. Matrices de confusión de los siete modelos (test de MNIST).

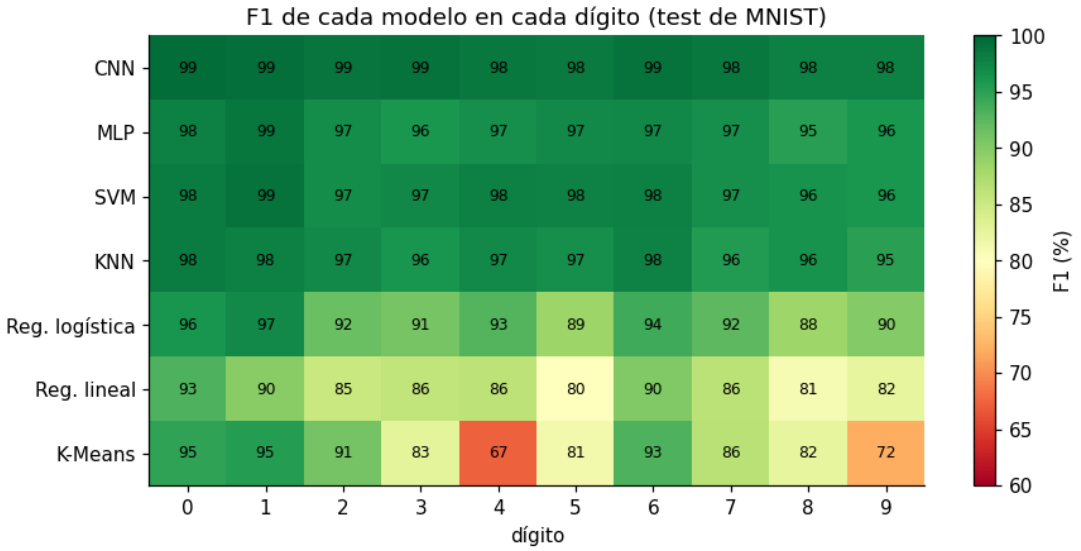


Figura 9. F1 de cada modelo en cada dígito.

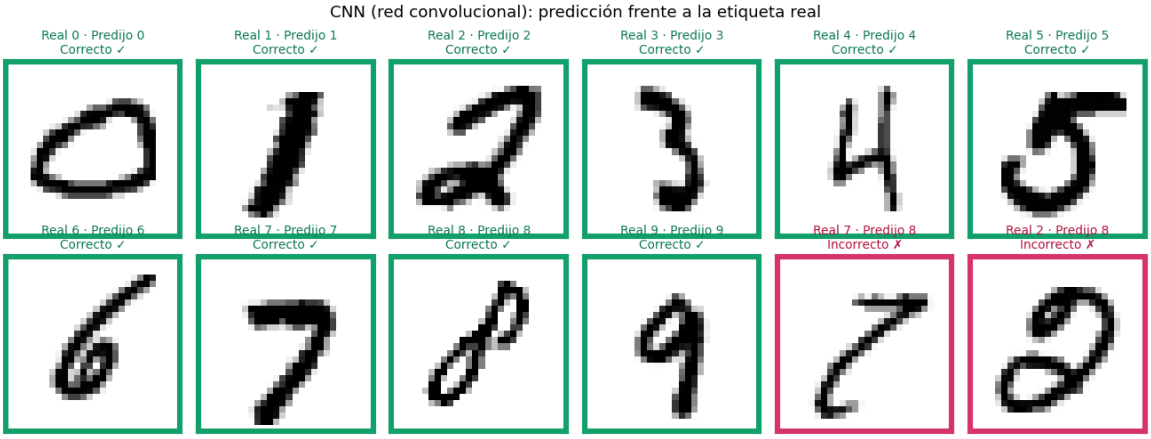


Figura 10. CNN (red convolucional): predicción frente a la etiqueta real.



Figura 11. MLP (red densa): predicción frente a la etiqueta real.

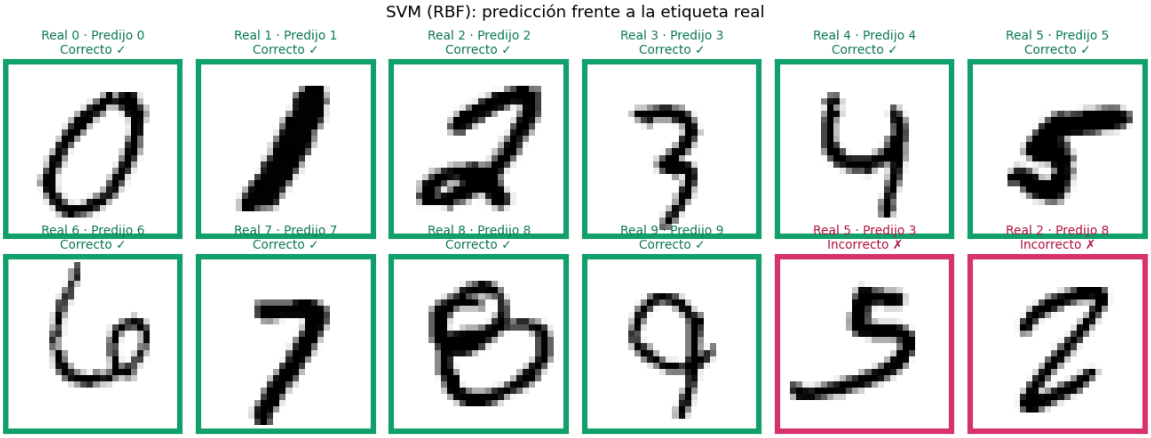


Figura 12. SVM (RBF): predicción frente a la etiqueta real.



Figura 13. KNN: predicción frente a la etiqueta real.



Figura 14. Regresión logística: predicción frente a la etiqueta real.



Figura 15. Regresión lineal: predicción frente a la etiqueta real.

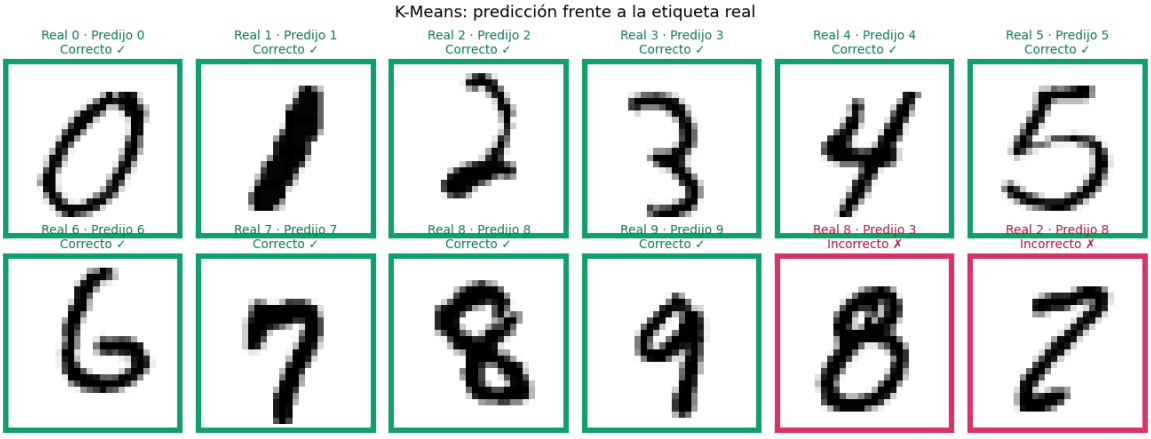


Figura 16. K-Means: predicción frente a la etiqueta real.



Figura 17. Errores de la CNN.

8. Sistema completo con datos ficticios

Con 84 números ficticios (hoja lisa, cuadriculada y campos de formulario), el mejor fue CNN: 99,1 % de dígitos bien y 96,4 % de números exactos. Donde más le costó fue en «Formulario» (91,7 % de números exactos): basta un dígito mal para fallar todo el número, y los campos de formulario tienen números largos (hasta 9 cifras).

Modelo	Dígitos bien (%)	Número exacto (%)
CNN	99,10	96,40
SVM	98,00	91,70
KNN	98,00	91,70
MLP	96,20	85,70
Reg. logística	92,40	70,20
K-Means	86,30	56,00
Reg. lineal	86,00	54,80

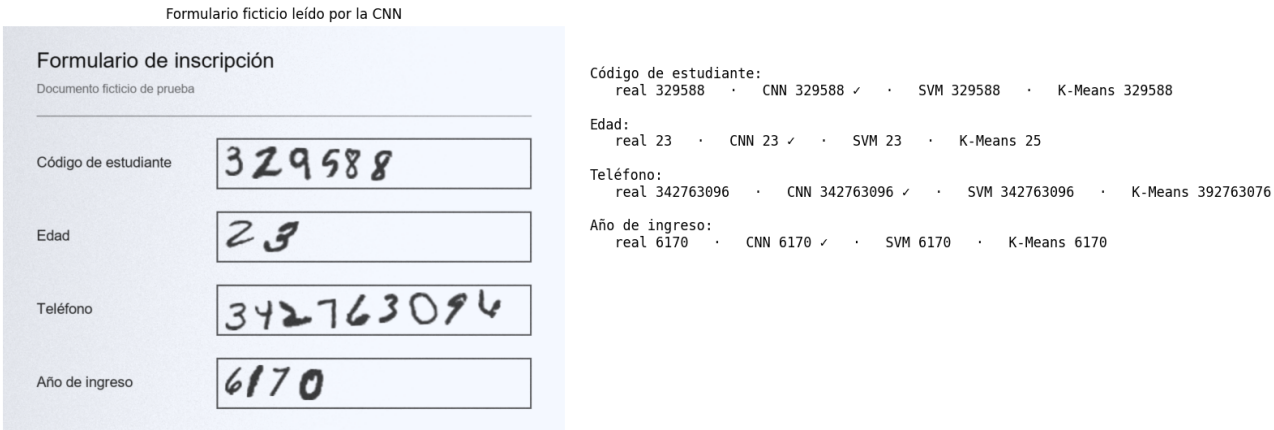


Figura 18. Formulario ficticio leído por los modelos.

9. Corrección y práctica

Igual que en la aplicación, los modelos que se equivocan pueden aprender de las fotos con su número real: practican con variantes de cada dígito fallado, repasan 3000 dígitos de MNIST y los de correcciones anteriores, y el cambio solo se guarda si no bajan más de 0,5 puntos en MNIST ni olvidan dígitos ya aprendidos. Cada corrección crea una versión nueva.

En esta ejecución se creó 1 versión nueva. En la práctica (Hoja cuadriculada, Muy difícil) los números exactos de la CNN pasaron de 70,0 % a 80,0 %, y en MNIST quedó en 98,51 % (antes 98,69 %).

Corrección con tus fotos

Modelo	Tus dígitos (antes → después)	Reserva (antes → después)	MNIST % (antes → después)	Resultado	Motivo
CNN	9/9	4/4	98,69	Sin cambios	No se equivocó: no necesita cambios.
MLP	9/9	4/4	96,85	Sin cambios	No se equivocó: no necesita cambios.
SVM	9/9	4/4	97,39	Sin cambios	No se equivocó: no necesita cambios.
KNN	9/9	4/4	96,78	Sin cambios	No se equivocó: no necesita cambios.
Reg. logística	8/9 → 9/9	4/4 → 4/4	92,33 → 90,07	Se mantuvo	Bajaba en MNIST de 92,33 % a 90,07 %: se mantuvo el anterior para no perder lo aprendido.
Reg. lineal	8/9 → 8/9	4/4 → 4/4	86,25 → 86,24	Se mantuvo	No logró corregir ningún dígito: se mantuvo el anterior.
K-Means	9/9	4/4	85,04	Sin cambios	No se equivocó: no necesita cambios.

Práctica: 10 imágenes (Hoja cuadriculada, Muy difícil)

Modelo	Tus dígitos (antes → después)	Reserva (antes → después)	MNIST % (antes → después)	Resultado	Motivo
CNN	24/31 → 26/31	15/16 → 14/16	98,69 → 98,51	Guardado ✓	Corrigió 2 de 7 dígitos sin perder en MNIST.
MLP	22/31 → 26/31	14/16 → 14/16	96,85 → 96,47	Guardado ✓	Corrigió 4 de 9 dígitos sin perder en MNIST.
SVM	22/31 → 31/31	16/16 → 16/16	97,39 → 97,44	Guardado ✓	Corrigió 9 de 9 dígitos sin perder en MNIST.
KNN	23/31 → 31/31	16/16 → 16/16	96,78 → 96,77	Guardado ✓	Corrigió 8 de 8 dígitos sin perder en MNIST.
Reg. logística	21/31 → 27/31	14/16 → 15/16	92,33 → 87,81	Se mantuvo	Bajaba en MNIST de 92,33 % a 87,81 %: se mantuvo el anterior para no perder lo aprendido.
Reg. lineal	22/31 → 22/31	15/16 → 15/16	86,25 → 86,19	Se mantuvo	No logró corregir ningún dígito: se mantuvo el anterior.
K-Means	20/31 → 31/31	12/16 → 12/16	85,04 → 82,65	Se mantuvo	Bajaba en MNIST de 85,04 % a 82,65 %: se mantuvo el anterior para no perder lo aprendido.

Versión	Origen	Modelos que cambiaron	CNN	MLP	SVM	KNN	Reg. logística	Reg. lineal	K-Means
v1	Entrenamiento inicial con MNIST	todos	98,69	96,85	97,39	96,78	92,33	86,25	85,04

Versión	Origen	Modelos que cambiaron	CNN	MLP	SVM	KNN	Reg. logística	Reg. lineal	K-Means
v2	Práctica: 10 imágenes (Hoja cuadriculada, Muy difícil)	CNN, MLP, SVM, KNN	98,51	96,47	97,44	96,77	92,33	86,25	85,04

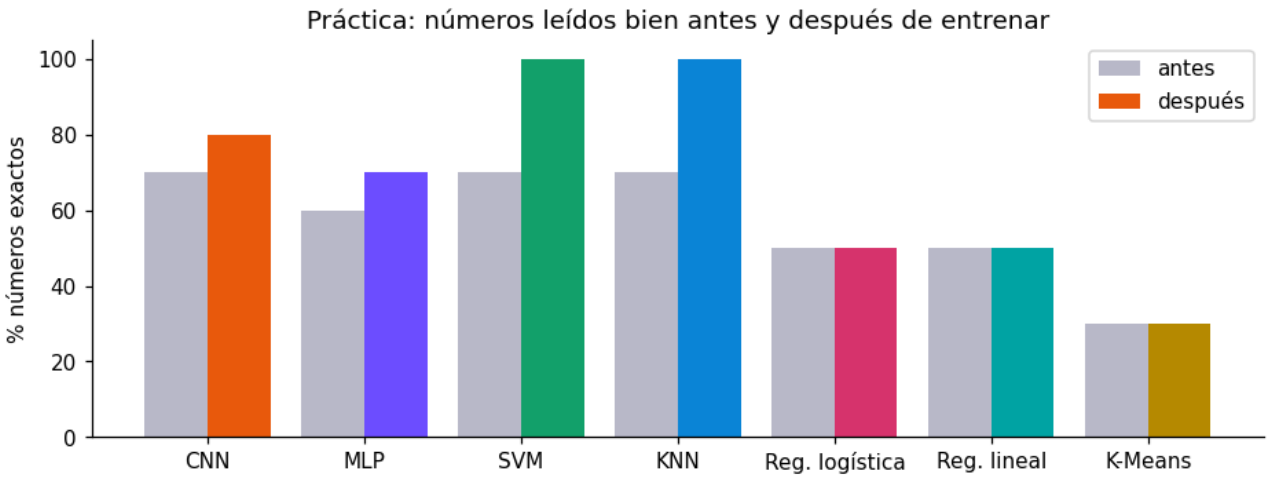


Figura 19. Práctica: números leídos bien antes y después de entrenar.

10. Conclusiones

El modelo recomendado es CNN (red convolucional): 98,69 % de exactitud en el test y F1 macro de 98,68 %.

Las alternativas clásicas (SVM, KNN) quedan cerca y sirven de control; los modelos lineales y K-Means muestran el límite de los métodos simples.

Limitaciones: MNIST es letra de personas estadounidenses en cajas limpias; con fotos reales conviene seguir corrigiendo a los modelos con los dígitos de TecnoForms (como hace la aplicación Cifra) y pedir fotos con buena luz y de frente.